

Machine Learning Lecture 2

Group 2

1 第二讲 Concentration Inequality(续)

1.1 Chernoff Bound

在上一讲中，我们已经学习了 Chernoff Bound 的在两种条件下是成立的，这里两种条件分别是独立同分布伯努利随机变量与在 $[0,1]$ 区间独立同分布的随机变量这两种情况，对于这两种情况具体的表述如下：

1.1.1 情况 1：独立同分布伯努利随机变量

定理 1 (Chernoff Bound - 情况 1). 设 X_1, X_2, \dots, X_n 为独立同分布的伯努利随机变量， $\mathbb{E}[X_i] = p$ ，则对于任意 $\delta > 0$ ，有：

$$\mathbb{P}\left(\left|\frac{1}{n}\sum_{i=1}^n X_i - p\right| \geq \delta\right) \leq e^{-O(n)}$$

1.1.2 情况 2：独立同分布有界随机变量

定理 2 (Chernoff Bound - 情况 2). 设 X_1, X_2, \dots, X_n 为独立同分布的随机变量， $X_i \in [0, 1]$ ， $\mathbb{E}[X_i] = p$ ，则：

$$\mathbb{P}\left(\left|\frac{1}{n}\sum_{i=1}^n X_i - p\right| \geq \delta\right) \leq e^{-O(n)}$$

对于这两种情况更详细的讨论以及证明可以参见上一讲的笔记。现在我们进一步放宽条件，考虑 X_1, X_2, \dots, X_n 为独立的随机变量， $X_i \in [0, 1]$ ， $\mathbb{E}[X_i] = p_i$ 的情况，这时对于情况二的证明中的

$$\mathbb{E}\left[e^{t\sum_{i=1}^n X_i}\right] = \prod_{i=1}^n \mathbb{E}[e^{tX_i}] = (\mathbb{E}[e^{tX}])^n \leq (pe^t + (1-p))^n$$

的第二个等式是不成立的，于是我们需要改进一下证明，值得欣喜的是通过一步放缩我们就可以解决这个问题，从而对这种情况得到同样的结论，表述如下：

1.1.3 情况 3: 独立非同有界随机变量

定理 3 (Chernoff Bound - 情况 3). 设 X_1, X_2, \dots, X_n 为独立的随机变量, $X_i \in [0, 1]$, $\mathbb{E}[X_i] = p_i$, 令 $p = \frac{1}{n} \sum_{i=1}^n p_i$, 则:

$$\mathbb{P} \left(\left| \frac{1}{n} \sum_{i=1}^n X_i - p \right| \geq \delta \right) \leq e^{-O(n)}$$

Proof. 正如前面所说的, 虽然 $\prod_{i=1}^n \mathbb{E}[e^{tX_i}] = (\mathbb{E}[e^{tX}])^n$ 不成立了, 但如果我们还能保证

$$\mathbb{E} \left[e^{t \sum_{i=1}^n X_i} \right] = \prod_{i=1}^n \mathbb{E}[e^{tX_i}] \leq (pe^t + (1-p))^n$$

, 那么我们还是可以解决这种情况, 后面的证明与情况二的证明一致。

注意情况二中的证明中我们用 Jensen 不等式证明了 $\mathbb{E}[e^{tX}] \leq pe^t + (1-p)$

于是实际上

$$\prod_{i=1}^n \mathbb{E}[e^{tX_i}] \leq \prod_{i=1}^n (p_i e^t + (1-p_i))$$

又注意到, 利用 Jensen 不等式和对数函数的凹性, 可得:

$$\frac{1}{n} \sum_{i=1}^n \ln(p_i e^t + (1-p_i)) \leq \ln \left(\sum_{i=1}^n \frac{1}{n} (p_i e^t + (1-p_i)) \right) = \ln(pe^t + (1-p))$$

即

$$\prod_{i=1}^n (p_i e^t + (1-p_i)) \leq (pe^t + (1-p))^n$$

结合这个放缩与前面的不等式, 我们就证明

$$\mathbb{E} \left[e^{t \sum_{i=1}^n X_i} \right] = \prod_{i=1}^n \mathbb{E}[e^{tX_i}] \leq (pe^t + (1-p))^n$$

, 从而对于这个情况我们就可以得到定理 3 描述的结果。 □

1.2 Chernoff Bound 的两种形式

注意到:

$$e^{-nD_B(p+\delta||p)} \leq e^{-2n\delta^2} \iff D_B(p+\delta||p) = (p+\delta) \ln \frac{p+\delta}{p} + (1-p-\delta) \ln \frac{1-p-\delta}{1-p} \geq 2\delta^2$$

而对于右边这个不等式是 Pinsker 不等式的一个直接结论，不过通过初等的求导与不等式也是可以证明在 $p, p + \delta$ 都属于 $(0,1)$ 时是成立的，由于步骤较为繁琐，证明放在最后仅供参考。

这样我们就得到下面关于 Chernoff Bound 的两个不同的表述：

- **additive Chernoff Bound**

$$\mathbb{P}\left(\frac{1}{n}\sum_{i=1}^n X_i - p \geq \delta\right) \leq e^{-2n\delta^2}$$

- **Relative Entropy Chernoff Bound**

$$\mathbb{P}\left(\frac{1}{n}\sum_{i=1}^n X_i - p \geq \delta\right) \leq e^{-nD_B(p+\delta\|p)}$$

1.3 Hoeffding 不等式

定理 4 (Hoeffding 不等式). 设随机变量 X_1, X_2, \dots, X_n 相互独立, $X_i \in [a_i, b_i]$, $-\infty < a_i < b_i < \infty$, $\mathbb{E}[X_i] = p_i$, $p = \frac{1}{n} \sum_{i=1}^n p_i$, 则：

$$\mathbb{P}\left(\frac{1}{n}\sum_{i=1}^n X_i - p \geq \delta\right) \leq e^{\frac{-2n^2\delta^2}{\sum_{i=1}^n (b_i - a_i)^2}}$$

对于这个不等式的证明，框架基本上与定理 3 是一致的，但要稍作修改且需要一个更强的放缩，故略去。同时格外要强调的是对于这几种情况独立条件都是尤为重要，如果没有独立条件的话一般情况下没有这样的不等式。

1.4 无放回抽样的集中不等式

考虑从有限总体 $a_1, a_2, \dots, a_N \in \{0, 1\}$ 中抽样，有两种策略：

- draw with replacement(有放回抽样)
- draw without replacement(无放回抽样)

对于第一种有放回的情况，显然它等价于独立同分布伯努利随机变量，也就是满足定理 1 的条件，自然是有 Chernoff Bound 的，关键是第二种情况，这里前面强调的独立条件丧失了，导致我们无法直接利用前面的结果。

记 X_1, \dots, X_n 来自有放回抽样，即为独立同分布伯努利随机变量， Y_1, \dots, Y_n 来自无放回抽样。由定理 1 的证明过程知利用独立性的关键步骤是证明

$$\mathbb{E}[e^{t(X_1+\dots+X_n)}] = (pe^t + (1-p))^n$$

，虽然因为独立性的丧失，我们不太可能对 Y_1, \dots, Y_n 也得到这个等式，不过我们可以考虑证明 $\mathbb{E}[e^{t(Y_1+\dots+Y_n)}] \leq \mathbb{E}[e^{t(X_1+\dots+X_n)}]$ ，如果这个不等式成立则我们也可以得到一样的结论。

幸运地，这个不等式也是对的，而且证明也很直接，就是通过比较它们泰勒展开的各项系数：

$$\begin{aligned}\mathbb{E}[e^{t(X_1+\dots+X_n)}] &= 1 + t\mathbb{E}\left[\sum_{i=1}^n X_i\right] + \frac{t^2}{2!}\mathbb{E}\left[\left(\sum_{i=1}^n X_i\right)^2\right] + \dots \\ \mathbb{E}[e^{t(Y_1+\dots+Y_n)}] &= 1 + t\sum_{i=1}^n \mathbb{E}[Y_i] + \frac{t^2}{2!}\left(\sum_{i=1}^n \mathbb{E}[Y_i^2] + 2\sum_{1 \leq i < j \leq n} \mathbb{E}[Y_i Y_j]\right) + \dots\end{aligned}$$

易知 $\mathbb{E}[X_i] = \mathbb{E}[Y_i]$ ，而且对于 $i = j$ ，有 $\mathbb{E}[X_i X_j] = \mathbb{E}[X_i^2] = \mathbb{E}[Y_i^2] = \mathbb{E}[Y_i Y_j]$ 。

当 $i \neq j$ 时，不妨让 $i < j$ ，因为

$$\mathbb{E}(X_i X_j) = \mathbb{P}(X_i = 1, X_j = 1) = \mathbb{P}(X_i = 1)\mathbb{P}(X_j = 1)$$

$$\mathbb{E}(Y_i Y_j) = \mathbb{P}(Y_i = 1, Y_j = 1) = \mathbb{P}(Y_i = 1)\mathbb{P}(Y_j = 1|Y_i = 1)$$

显然 $\mathbb{P}(X_i = 1) = \mathbb{P}(Y_i = 1)$ ，而因为 Y_i, Y_j 负相关，在 Y_i 抽出球下， Y_j 抽出球的几率是变小的， $\mathbb{P}(Y_j = 1|Y_i = 1) < \mathbb{P}(Y_j = 1)$ ，所以我们可以得到 $\mathbb{E}(Y_i Y_j) \leq \mathbb{E}(X_i X_j)$

对于更高阶项的系数我们也有类似的结论，若对于 $n = k$ 成立，我们可以证明 $n = k + 1$ 成立：

$$\mathbb{E}(X_{i_1}, \dots, X_{i_{k+1}}) = \mathbb{P}(X_{i_{k+1}} = 1|X_{i_1} = 1, \dots, X_{i_k} = 1) = \mathbb{P}(X_{i_{k+1}} = 1)\mathbb{P}(X_{i_1} = 1, \dots, X_{i_k} = 1)$$

$$\mathbb{E}(Y_{i_1}, \dots, Y_{i_{k+1}}) = \mathbb{P}(Y_{i_{k+1}} = 1|Y_{i_1} = 1, \dots, Y_{i_k} = 1) < \mathbb{P}(Y_{i_{k+1}} = 1)\mathbb{P}(Y_{i_1} = 1, \dots, Y_{i_k} = 1)$$

$$\mathbb{P}(Y_{i_{k+1}} = 1)\mathbb{P}(Y_{i_1} = 1, \dots, Y_{i_k} = 1) < \mathbb{P}(X_{i_{k+1}} = 1)\mathbb{P}(X_{i_1} = 1, \dots, X_{i_k} = 1)$$

从而我们便可以证明 $\mathbb{E}e^{t(X_1+\dots+X_n)} \geq \mathbb{E}e^{t(Y_1+\dots+Y_n)}$ ，也就可以得到下面的定理。

定理 5 (无放回抽样的集中不等式). 设 Y_1, \dots, Y_n 是从 $a_1, \dots, a_N \in \{0, 1\}$ 中无放回抽取的样本，令 $p = \frac{1}{N} \sum_{j=1}^N a_j$ ，则：

$$\mathbb{P}\left(\frac{1}{n} \sum_{i=1}^n Y_i - p \geq \delta\right) \leq e^{-2n\delta^2}$$

2 第三讲: VC Theory for Generalization

2.1 Occam 剃刀原理

简单的模型通常具有更好的泛化能力，而复杂的模型在训练数据上可能拟合得更好，但泛化能力较差。

2.2 监督学习框架

1. 训练数据: $(x_1, y_1), \dots, (x_n, y_n)$, 其中 $x_i \in \mathcal{X}$, $y_i \in \mathcal{Y}$, 独立同分布于 D_{XY}

2. 训练过程:

- 从 hypothesis space \mathcal{F} 中选择 \hat{f} , 使得在训练数据上的损失较小
- Training error = $\frac{1}{n} \sum_{i=1}^n I(y_i \neq \hat{f}(x_i))$

3. 推断过程:

- Population error / Generalization error = $\mathbb{P}(Y \neq \hat{f}(X))$

2.3 Generalization Gap

Generalization Gap 定义为:

$$\mathbb{P}(Y \neq \hat{f}(X)) - \frac{1}{n} \sum_{i=1}^n I(y_i \neq \hat{f}(x_i))$$

上式后半段表示训练误差;

令 $Z_i = I(y_i \neq \hat{f}(x_i))$, 则泛化差距可写为:

$$\mathbb{E}[Z] - \frac{1}{n} \sum_{i=1}^n Z_i$$

注意, 这里的 Z_1, \dots, Z_n 不是独立的, 因此不能直接应用前面的 Chernoff 界。

2.4 有限假设空间的情况 (简化设置)

假设假设空间 \mathcal{F} 是有限的, 即 $|\mathcal{F}| < \infty$ 。考虑最坏情况:

$$\begin{aligned} & \mathbb{P} \left(\mathbb{P}(Y \neq \hat{f}(X)) - \frac{1}{n} \sum_{i=1}^n I(y_i \neq \hat{f}(x_i)) \geq \epsilon \right) \\ & \leq \mathbb{P} \left(\exists f \in \mathcal{F}, \mathbb{P}(Y \neq f(X)) - \frac{1}{n} \sum_{i=1}^n I(y_i \neq f(x_i)) \geq \epsilon \right) \end{aligned}$$

应用联合界 (union bound):

$$\leq \sum_{f \in \mathcal{F}} \mathbb{P} \left(\mathbb{P}(Y \neq f(X)) - \frac{1}{n} \sum_{i=1}^n I(y_i \neq f(x_i)) \geq \epsilon \right)$$

对于每个固定的 $f \in \mathcal{F}$, $I(y_i \neq f(x_i))$ 是独立同分布的伯努利随机变量, 因此可以应用 Chernoff Bound:

$$\leq |\mathcal{F}| e^{-2n\epsilon^2}$$

这一结果表明:

- 简单的模型 (假设空间小) 会有更好的泛化能力, 但在训练数据上的拟合可能较差
- 复杂的模型 (假设空间大) 在训练数据上可能拟合得更好, 但泛化能力较差

VC 理论则是在假设空间无限大时, 对这种权衡关系进行定量分析的理论框架。

2.5 附注

我们旨在证明以下不等式成立:

$$D_B(p + \delta || p) = (p + \delta) \ln \frac{p + \delta}{p} + (1 - p - \delta) \ln \frac{1 - p - \delta}{1 - p} \geq 2\delta^2$$

其中 $0 < p < 1$, 且 δ 的取值需保证 $0 < p + \delta < 1$ 。

证明. 为了证明此不等式, 我们构造一个辅助函数 $g(\delta)$:

$$g(\delta) = \left((p + \delta) \ln \frac{p + \delta}{p} + (1 - p - \delta) \ln \frac{1 - p - \delta}{1 - p} \right) - 2\delta^2$$

我们的目标是证明对于所有有效的 δ , 都有 $g(\delta) \geq 0$ 。

第一步: 分析函数在 $\delta = 0$ 的取值

首先, 计算当 $\delta = 0$ 时函数的值:

$$\begin{aligned} g(0) &= \left(p \ln \frac{p}{p} + (1-p) \ln \frac{1-p}{1-p} \right) - 2(0)^2 \\ &= (p \ln(1) + (1-p) \ln(1)) - 0 \\ &= 0 \end{aligned}$$

这表明在 $\delta = 0$ 时, 不等式取等号。

第二步: 计算一阶导数 $g'(\delta)$

接下来, 我们对 $g(\delta)$ 求一阶导数。令 $f(\delta) = (p+\delta) \ln \frac{p+\delta}{p} + (1-p-\delta) \ln \frac{1-p-\delta}{1-p}$ 。通过求导法则, 我们得到 $f'(\delta)$:

$$f'(\delta) = \ln \left(\frac{p+\delta}{p} \right) - \ln \left(\frac{1-p-\delta}{1-p} \right)$$

因此, $g(\delta)$ 的一阶导数为:

$$g'(\delta) = f'(\delta) - 4\delta = \ln \left(\frac{p+\delta}{p} \right) - \ln \left(\frac{1-p-\delta}{1-p} \right) - 4\delta$$

在 $\delta = 0$ 处, 一阶导数为:

$$g'(0) = \ln(1) - \ln(1) - 0 = 0$$

这表明 $\delta = 0$ 是函数 $g(\delta)$ 的一个驻点 (critical point)。

第三步: 计算二阶导数 $g''(\delta)$

为了判断驻点的性质, 我们继续求二阶导数 $g''(\delta)$:

$$\begin{aligned} g''(\delta) &= \frac{d}{d\delta} g'(\delta) \\ &= \frac{1}{p+\delta} - \left(\frac{-1}{1-p-\delta} \right) - 4 \\ &= \frac{1}{p+\delta} + \frac{1}{1-p-\delta} - 4 \end{aligned}$$

第四步: 证明 $g''(\delta) \geq 0$

证明的关键在于证明 $g''(\delta) \geq 0$ 。这等价于证明:

$$\frac{1}{p+\delta} + \frac{1}{1-p-\delta} \geq 4$$

我们可以利用一个基本不等式: 对于任意两个正数 a 和 b , 有 $\frac{1}{a} + \frac{1}{b} \geq \frac{4}{a+b}$ 。

令 $a = p + \delta$ 和 $b = 1 - p - \delta$ 。由于 $0 < p + \delta < 1$ ，所以 $a > 0$ 且 $b > 0$ 。它们的和是：

$$a + b = (p + \delta) + (1 - p - \delta) = 1$$

因此，

$$\frac{1}{p + \delta} + \frac{1}{1 - p - \delta} \geq \frac{4}{(p + \delta) + (1 - p - \delta)} = \frac{4}{1} = 4$$

这就证明了 $f''(\delta) \geq 4$ （其中 $f''(\delta)$ 是 $g''(\delta)$ 的第一部分），所以

$$g''(\delta) = \left(\frac{1}{p + \delta} + \frac{1}{1 - p - \delta} \right) - 4 \geq 4 - 4 = 0$$

第五步：结论

我们已经证明了 $g''(\delta) \geq 0$ 恒成立，这意味着 $g(\delta)$ 是一个凸函数（convex function）。对于凸函数，一阶导数为零的点是其全局最小值点。由于 $g'(0) = 0$ ，所以 $\delta = 0$ 是 $g(\delta)$ 的全局最小值点。该全局最小值为 $g(0) = 0$ 。

因此，对于所有有效的 δ ，我们有 $g(\delta) \geq g(0) = 0$ 。即：

$$(p + \delta) \ln \frac{p + \delta}{p} + (1 - p - \delta) \ln \frac{1 - p - \delta}{1 - p} - 2\delta^2 \geq 0$$

移项后即得原不等式：

$$(p + \delta) \ln \frac{p + \delta}{p} + (1 - p - \delta) \ln \frac{1 - p - \delta}{1 - p} \geq 2\delta^2$$

□